



NHÓM 3

CSPs, Combinatorial & Routing Optimization

SUDOKU-BENCH: EVALUATING CREATIVE REASONING WITH SUDOKU VARIANTS

Môn học: CS106 - Trí Tuệ Nhân Tạo

GVHD: Lương Ngọc Hoàng





THÀNH VIÊN TRONG NHÓM

Môn học: CS106 - Trí Tuệ Nhân Tạo

CSPs, Combinatorial & Routing Optimization

NHÓM 4

MSSV	HỌ TÊN
23520986	Phan Công Nam
23520732	Đặng Anh Khoa
23520705	Phạm Minh Bảo Khang
23520662	Nguyễn Khang Hy

Sudoku-Bench: Evaluating creative reasoning with Sudoku variants



TABLE OF CONTENT



**VẤN ĐỀ NGHIÊN CỨU
VÀ PAPER THAM CHIẾU**



CƠ SỞ LÝ THUYẾT



**THIẾT KẾ ĐÁNH GIÁ
VÀ PHẠM VI TÁI HIỆN**



**PIPELINE THỰC
NGHIỆM CỦA NHÓM**



KẾT QUẢ VÀ PHÂN TÍCH




**DEMO, KẾT LUẬN VÀ
HƯỚNG PHÁT TRIỂN**





01 VẤN ĐỀ NGHIÊN CỨU

*Sudoku-Bench: Evaluating creative reasoning
with Sudoku variants*





1.1 VẤN ĐỀ NGHIÊN CỨU



Các mô hình ngôn ngữ lớn hiện nay thể hiện năng lực rất mạnh trong nhiều tác vụ:

- Trả lời câu hỏi tự nhiên;
- Sinh văn bản;
- Hỗ trợ lập trình;
- Giải thích kiến thức;
- Thực hiện các bài toán có dạng / mẫu quen thuộc.

Tuy nhiên, với các bài toán logic có ràng buộc chặt, yêu cầu Output không chỉ là *nghe hợp lý* mà phải đúng tuyệt đối:

- Mỗi bước đi phải thỏa tất cả ràng buộc liên quan;
- Một hành động sai không thể quay lui.
- Lời giải cuối cần được kiểm tra bằng nghiệm chuẩn;
- Prompt đơn giản chưa đủ để LLM ra được đáp án đúng.

Pattern Matching	Constraint Reasoning
Dựa vào các dạng/ mẫu quen thuộc	Dựa vào luật và ràng buộc
Câu trả lời có thể nghe hợp lý	Câu trả lời phải đúng hoàn toàn
Khó phát hiện sai nếu không có ground truth	Có thể validate
Phù hợp với tác vụ ngôn ngữ	Phù hợp với CSP, Sudoku, lập lịch



1.2 PAPER THAM CHIẾU

Mục tiêu của paper gốc:


- Đánh giá năng lực *creative reasoning* của LLM;
- Dùng ***Sudoku variants*** thay vì Sudoku chuẩn nhằm giảm khả năng mô hình chỉ dựa vào mẫu Sudoku mà mô hình đã được học;
- Đánh giá bằng nghiệm chuẩn và phân tích lỗi.

Điểm quan trọng:

- Kiểm tra việc mô hình có thể **suy luận và trả lời được với các ràng buộc** hay không.

Lí do chọn Sudoku variants:

- Luật chơi và ràng buộc phức tạp;
- Không gian trạng thái đa dạng, phong phú;
- Phù hợp để so sánh single-shot và multi-step.





02

CƠ SỞ LÝ THUYẾT VÀ PAPER THAM CHIẾU

*Sudoku-Bench: Evaluating creative reasoning
with Sudoku variants*





2.1 CÁC RÀNG BUỘC CỦA BIẾN THỂ SUDOKU

Một biến thể Sudoku gồm có:

- **Các ô trống cần điền**
- **Miền giá trị:** các chữ số hợp lệ được phép điền vào.
- **Ràng buộc chuẩn:** không lặp số theo hàng, cột, vùng.
- **Ràng buộc biến thể:** cage sum, arrow, thermometer, knight move, v.v.;
- **Nghiệm chuẩn:** có duy nhất 1 nghiệm.

Điểm quan trọng với LLM trong việc giải quyết các puzzle:

- Model phải đọc và hiểu luật được mô tả bằng ngôn ngữ tự nhiên;
- Model phải duy trì nhiều ràng buộc cùng lúc;
- Một bộ validator kiểm tra quyết định của LLM.



2.2 DATASET CỦA PAPER

Paper chuyển puzzle sang dạng text gồm:

- Luật chung của Sudoku;
- Luật riêng của các variants;
- Kích thước lưới;
- Tọa độ các ô;
- Mô tả các ràng buộc đặc biệt;
- Yêu cầu output có thể kiểm chứng.

Phạm vi paper:

Thành phần	Paper gốc
Core benchmark	challenge_100
Số puzzle chính	100 Sudoku variants
Kích thước	4x4, 6x6, 9x9
Kiểu đánh giá	single-shot và multi-step
Metric	solve rate, correct placements, error type



2.3 SUDOKU VARIANTS



Một số biến thể phổ biến

Variant	Ràng buộc bổ sung
Knight's Move	Các ô cách nhau như nước đi quân mã không được trùng số
Arrow	Tổng các ô trên thân mũi tên bằng số ở vòng tròn gốc
Thermometer	Các số tăng dần dọc theo nhiệt kế
Killer Cage	Tổng các ô trong cage bằng một giá trị cho trước và không lặp số

Vì sao variants khó hơn Sudoku chuẩn?

- Một ô chịu nhiều loại ràng buộc cùng lúc.
- Có nhiều ràng buộc cục bộ nhưng ảnh hưởng toàn cục.
- Bước đi đầu tiên không phải lúc nào cũng dễ tìm.



2.4 KILLER SUDOKU

Killer Sudoku = Sudoku chuẩn + ràng buộc cage.

Mỗi cage gồm:

- Một nhóm ô;
- Một số tổng mục tiêu;
- Điều kiện là tổng các ô bằng tổng mục tiêu;
- Các số trong cage không được lặp.

Ví dụ:

Cage: $r1c1 + r2c1 = 3$

Digits allowed in 6x6: 1..6

Possible combination: {1,2}

Tuy nhiên:

- Biết tổ hợp {1,2} là chưa đủ;
- Cần xác định ô nào là 1, ô nào là 2;
- Liên hệ ràng buộc với hàng, cột, khối và các cage khác.

3 {1, 2}	7		10		4
{1, 2}	9	11			
8		6		10	
	5	12	7		
9				6	8
		7			

bảng Killer Sudoku 6x6





2.5 BREAK-IN

Trong nhiều màn chơi:

- Có rất ít số được điền sẵn hoặc thậm chí không có số nào.
- Cần phát hiện một bước đi then chốt để khởi đầu.


Break-in có vai trò lớn đối với LLM:

- Kiểm tra khả năng chọn hướng suy luận;
- Kiểm tra khả năng kết hợp nhiều luật;
- Kiểm tra việc mô hình có thể tạo ra một bước đi chắc chắn thay vì đoán.






2.5 BREAK-IN



Tổng giá trị Cages:
 $3 + 9 + 10 = 22$


3 ô này cùng 1 Cage
có tổng là 10




Nhưng tổng 1 vùng
chỉ có thể là 21

Dư 1 nên chắc
chắn ô này là 1

Break-in
được tìm ra



Tiếp tục
suy luận






03

THIẾT KẾ ĐÁNH GIÁ VÀ PHẠM VI TÁI HIỆN BÀI BÁO

Sudoku-Bench: Evaluating creative reasoning with Sudoku variants



3.1 THIẾT KẾ ĐÁNH GIÁ CỦA PAPER

1. **Single-shot phù hợp để kiểm tra:** khả năng giải trực tiếp chỉ đưa ra kết quả cuối cùng với chi phí thấp.
2. **Multi-step phù hợp để kiểm tra:** quá trình suy luận; khả năng duy trì trạng thái; lỗi xuất hiện ở bước nào.

Tiêu chí	Single-shot	Multi-step
Cách gọi model	Một lần cho toàn bộ puzzle	Nhiều vòng tương tác
Output	Grid hoàn chỉnh	Một bước đi mỗi vòng
Chi phí API	Thấp hơn	Cao hơn nhiều
Phân tích quá trình	Hạn chế	Chi tiết hơn
Biết bước sai	Khó	Có

3.2 PHẠM VI TÁI HIỆN CỦA NHÓM

Biến thể chính: Killer Sudoku;

Model benchmark hiện tại: Gemini 2.5 Flash; Gemini 2.5 Pro; Gemini 3.1 Flash Lite; Gemini 3.5 Flash;

Phương pháp giải quyết: single-prompt; multi-step;

Dataset: 5 puzzle 6x6 easy; 2 puzzle 9x9 hard;

Lý do rút gọn phạm vi:

- **Giới hạn thời gian:** Mỗi lượt 9x9 tốn 2-3 giờ.
- **Chi phí gọi API rất lớn.**

Kích thước	Số ô	Số lượt gọi tối thiểu
6x6	36	72
9x9	81	162



04

PIPELINE THỰC NGHIỆM CỦA NHÓM

*Sudoku-Bench: Evaluating creative reasoning
with Sudoku variants*





4.1 DATASET

Mỗi puzzle được lưu trong file JSON:

```
{
  "id": 1,
  "difficulty": "easy",
  "grid_size": 6,
  "puzzle": [[0,0,0,0,0,0], ...],
  "solution": [[1,3,5,2,6,4], ...],
  "cages": [
    {"cells": [[0,0],[1,0]], "sum": 3}
  ]
}
```

Dataset hiện tại:

Puzzle	Size	Difficulty
1-5	6x6	easy
6-7	9x9	hard

Ý nghĩa các trường:


Trường	Ý nghĩa
id	Mã puzzle
difficulty	Độ khó
grid_size	Kích thước lưới
puzzle	Board ban đầu
solution	Nghiệm chuẩn
cages	Danh sách cage và tổng mục tiêu



4.2 PIPELINE TỔNG QUÁT

Các thành phần:

- **Data Loader:** đọc puzzle, solution và cages.
- **Prompt Builder:** tạo prompt từ luật, board, cages và cheat sheet.
- **LLM API:** gọi các model Gemini 2.5 và Gemini 3.x.
- **Parser:** trích output JSON từ phản hồi.
- **Validator:** so sánh với nghiệm chuẩn.
- **Logger:** lưu từng bước để phân tích.
- **Evaluation Notebook:** tổng hợp solve rate, correct placements, error type





4.3 SINGLE-SHOT EVALUATION

Input cho model:

- Luật Sudoku chuẩn;
- Luật Killer Sudoku;
- Board ban đầu;
- Danh sách cages;
- Cheat sheet các tổ hợp Killer cage;
- Yêu cầu trả về grid hoàn chỉnh.

Output mong muốn:

- Một bảng hoàn chỉnh;
- Đúng định dạng để parser đọc;
- Tất cả ô phải khớp nghiệm chuẩn.

Ưu điểm:

- Ít lượt gọi API;
- Dễ chạy cho nhiều puzzle;
- Phù hợp để có baseline nhanh.

Hạn chế:

- Khó biết mô hình sai từ bước nào;
- Mô hình có thể đưa ra lời giải gần đúng nhưng vẫn fail.





4.4 MULTI-STEP EVALUATION

Mỗi vòng gồm hai giai đoạn:

1. Analysis

- Mô hình phân tích trạng thái hiện tại.
- Xem xét luật Sudoku, cage, các ô đã điền.

2. Fill

- Mô hình chọn đúng một ô để điền.
- Trả về cell, value, reasoning và độ chắc chắn.

Sau mỗi bước fill:

- Board được cập nhật;
- Validator kiểm tra ngay;
- Nếu đúng thì tiếp tục;
- Nếu sai thì dừng phiên chạy.

Luật quan trọng:

Điền rồi không hoàn tác. Sai một ô là phiên chạy thất bại.





4.4 MULTI-STEP EVALUATION

Analysis template 6x6:

1. Constraint Analysis

- ****Active Rules****: [State the specific variant rules affecting the current empty cells]
- ****Global Observations****: [Note any high-level geometric or mathematical interactions, e.g., "The arrow in box 2 restricts cells r1c4 and r1c5 to small digits"]

2. Candidate Elimination (Pencil Marks)

Analyze the most restricted cells, rows, columns, or regions. List remaining candidates.

- ****r[x]c[y]****: {[candidates]} - Reason: [Briefly explain why other digits are eliminated]
- ****r[x]c[y]****: {[candidates]} - Reason: [Briefly explain why other digits are eliminated]

3. Deductions & Bottlenecks

- ****Single Candidates (Naked/Hidden Singles)****: [List any cell that is reduced to exactly ONE possible digit, e.g., "r4c6 MUST be 6 because..."]
- ****Contradiction Checks****: [Mention any hypothetical placements that immediately break the rules]



4.5 KILLER SUDOKU CHEAT SHEET

Cheat sheet cung cấp các tổ hợp cage hợp lệ.

Ví dụ:

2-cell cage sum 3: {1,2}
2-cell cage sum 5: {1,4}, {2,3}
3-cell cage sum 6: {1,2,3}

Vai trò:

- Giúp model giảm lỗi tính toán tổ hợp cơ bản;
- Cung cấp context rõ hơn cho Killer Sudoku;
- Hỗ trợ model tập trung vào việc kết hợp ràng buộc;
- Không trực tiếp cho biết lời giải của puzzle.

Nhấn mạnh: *Cheat sheet không solve thay mô hình. Nó chỉ đưa các tổ hợp hợp lệ; mô hình vẫn phải suy luận ô nào nhận giá trị nào.*

Trạng thái hiện tại:

- Cheat sheet 6x6 đã dùng trong benchmark 4 model.
- Cheat sheet/prompt 9x9 đã được tách riêng trong pipeline 9x9.
- Benchmark cuối đã chạy đủ 6x6 và 9x9 trên 4 model.
- Trên 9x9 multi-step, Gemini 2.5 Pro và Gemini 3.5 Flash đều giải được 2/2 puzzle



4.5 KILLER SUDOKU CHEAT SHEET



Một số bảng cheatsheet:

2-Cell Cage Combinations

Sum	Combinations
:-----	:-----
3	12
4	13
5	14, 23
6	15, 24
7	16, 25, 34
8	26, 35
9	36, 45
10	46
11	56

3-Cell Cage Combinations

Sum	Combinations
:-----	:-----
6	123
7	124
8	125, 134
9	126, 135, 234
10	136, 145, 235
11	146, 236, 245
12	156, 246, 345
13	256, 346
14	356
15	456

4-Cell Cage Combinations

Sum	Combinations
:-----	:-----
10	1234
11	1235
12	1236, 1245
13	1246, 1345
14	1256, 1346, 2345
15	1356, 2346
16	1456, 2356
17	2456
18	3456



4.6 ĐỊNH DẠNG OUTPUT MULTI-STEP

Output JSON của bước Fill:

```
{
  "cell": "r2c5",
  "value": 1,
  "reasoning": "The cage sum forces this cell to be 1.",
  "is_certain": true
}
```

Vì sao cần JSON:

- Dễ parse tự động;
- Tránh output lan man;
- Dễ validate;
- Dễ lưu log từng bước;
- Dễ trích ví dụ cho phân tích lỗi.

Các trường chính:

Trường	Ý nghĩa
cell	ô được chọn
value	giá trị điền
reasoning	lý do mô hình đưa ra
is_certain	mô hình có chắc chắn không




4.7 VALIDATOR

Với single-shot:

- Kiểm tra toàn bộ grid cuối;
- Status = Success nếu prediction khớp solution.

Với multi-step:

- Kiểm tra sau từng bước fill;
- Nếu sai một ô thì dừng ngay;
- Lưu error type và số bước đã đi.





05 KẾT QUẢ VÀ PHÂN TÍCH

*Sudoku-Bench: Evaluating creative reasoning
with Sudoku variants*





5.1 KẾT QUẢ SINGLE-SHOT HIỆN TẠI



Single-shot đã chạy xong trên 7 puzzle

Model	Kết quả	Solve rate
Gemini 2.5 Flash	4/7 solved	57.14%
Gemini 2.5 Pro	5/7 solved	71.43%
Gemini 3.1 Flash Lite	0/7 solved	0%
Gemini 3.5 Flash	6/7 solved	85.71%

5.2 CHI TIẾT SINGLE-SHOT 6X6

Kết quả single-shot trên 5 puzzle 6x6 easy

Puzzle	Gemini 2.5 Flash	Gemini 2.5 Pro	Gemini 3.1 Flash Lite	Gemini 3.5 Flash
1	Failed	Success	Failed	Success
2	Success	Success	Failed	Success
3	Success	Success	Failed	Success
4	Success	Success	Failed	Success
5	Success	Success	Failed	Success

Nhận xét:

- 6x6 là mức mà single-shot có thể xử lý tương đối tốt.
- Pro ổn định hơn Flash trong tập 6x6 hiện tại.
- Flash vẫn có trường hợp trả về grid sai dù puzzle ở mức easy.

5.3 CHI TIẾT SINGLE-SHOT 9X9

Model	Kết quả 9x9 single-shot	Solve rate	Ghi chú
Gemini 2.5 Flash	0/2 solved	0%	Sai cả puzzle 06 và 07
Gemini 2.5 Pro	0/2 solved	0%	Sai cả puzzle 06 và 07
Gemini 3.1 Flash Lite	0/2 solved	0%	Sai cả puzzle 06 và 07
Gemini 3.5 Flash	1/2 solved	50%	Giải được puzzle 07, fail puzzle 06

Nhận xét:

- single-shot đủ mạnh cho 6x6 easy nhưng giảm mạnh khi lên 9x9 hard.
- Gemini 3.5 Flash là model duy nhất giải được một puzzle 9x9 bằng single-shot.
- Kết quả này tạo đối chứng tốt cho multi-step: cùng 9x9 nhưng mode tương tác khác cho kết quả rất khác.

5.3 KẾT QUẢ MULTI-STEP HIỆN TẠI

Model	Kết quả	Solve rate
Gemini 2.5 Flash	4/7 solved	57.12%
Gemini 2.5 Pro	6/7 solved	85.71%
Gemini 3.1 Flash Lite	0/7 solved	0%
Gemini 3.5 Flash	7/7 solved	100%


5.4 CHI TIẾT MULTI-STEP 6X6

Puzzle	2.5 Flash	2.5 Pro	3.1 Flash Lite	3.5 Flash
1	Success / 37 steps	Success / 36 steps	Failed / 14 steps	Success / 36 steps
2	Failed / 5 steps	Success / 36 steps	Failed / 13 steps	Success / 36 steps
3	Success / 36 steps	Success / 36 steps	Failed / 1 step	Success / 36 steps
4	Success / 36 steps	Success / 37 steps	Failed / 14 steps	Success / 36 steps
5	Success / 36 steps	Failed / 5 steps	Failed / 1 step	Success / 36 steps

Nhận xét:

- Khi success, số bước xấp xỉ số ô cần điền.
- Gemini 3.5 Flash là model multi-step 6x6 tốt nhất hiện tại.
- Gemini 3.1 Flash Lite thường fail sớm, cho thấy model yếu hơn
- Số bước trước khi fail là dữ liệu tốt để so sánh độ bền suy luận của model.

Lưu ý: Các step 37 (trên 6x6) nghĩa là mô hình điền trùng hoàn toàn 1 bảng nhưng vẫn đúng.



5.5 KẾT QUẢ MULTI-STEP 9X9

Model	Kết quả 9x9 multi-step	Solve rate	Avg correct placements	Error type chính
Gemini 2.5 Flash	0/2 solved	0%	5.0/81	No Certain Move
Gemini 2.5 Pro	2/2 solved	100%	81.0/81	Success
Gemini 3.1 Flash Lite	0/2 solved	0%	0.0/81	No Certain Move
Gemini 3.5 Flash	2/2 solved	100%	81.0/81	Success

5.6 SO SÁNH SINGLE-SHOT VÀ MULTI-STEP

Model	6x6 single	6x6 multi	9x9 single	9x9 multi
Gemini 2.5 Flash	4/5	4/5	0/2	0/2
Gemini 2.5 Pro	5/5	4/5	0/2	2/2
Gemini 3.1 Flash Lite	0/5	0/5	0/2	0/2
Gemini 3.5 Flash	5/5	5/5	1/2	2/2


Nhận xét:

- 6x6 easy chưa đủ khó với model mạnh: Gemini 2.5 Pro và Gemini 3.5 Flash đều đạt kết quả cao. 9x9 hard tạo khác biệt rõ hơn giữa các model và các mode.
- Multi-step không phải luôn luôn tốt hơn trên 6x6, nhưng cực kỳ quan trọng trên 9x9.
- Gemini 3.5 Flash là model ổn định nhất trong phạm vi benchmark của nhóm.
- Gemini 3.1 Flash Lite là baseline yếu, fail toàn bộ trong cả single-shot và multi-step.
- Khi lên 9x9 hard, hiệu năng giảm rõ: chỉ Gemini 3.5 Flash giải được 1/2, các model còn lại 0/2. Điều này cho thấy 9x9 là mức khó phù hợp hơn để phân tách năng lực reasoning.



5.1 KẾT QUẢ SINGLE-SHOT HIỆN TẠI

Biểu đồ trực quan:





5.6 SO SÁNH SINGLE-SHOT VÀ MULTI-STEP



Kết luận: Đánh giá LLM trên Sudoku variants cần xem đồng thời kích thước puzzle, model và chế độ tương tác.

Per-puzzle outcome heatmap

	P01	P02	P03	P04	P05	P06	P07
6x6 / multi / gemini-2.5-flash	S	F	S	S	S	-	-
6x6 / multi / gemini-2.5-pro	S	S	S	S	F	-	-
6x6 / multi / gemini-3.1-flash-lite	F	F	F	F	F	-	-
6x6 / multi / gemini-3.5-flash	S	S	S	S	S	-	-
6x6 / single / gemini-2.5-flash	F	S	S	S	S	-	-
6x6 / single / gemini-2.5-pro	S	S	S	S	S	-	-
6x6 / single / gemini-3.1-flash-lite	F	F	F	F	F	-	-
6x6 / single / gemini-3.5-flash	S	S	S	S	S	-	-
9x9 / multi / gemini-2.5-flash	-	-	-	-	-	F	F
9x9 / multi / gemini-2.5-pro	-	-	-	-	-	S	S
9x9 / multi / gemini-3.1-flash-lite	-	-	-	-	-	F	F
9x9 / multi / gemini-3.5-flash	-	-	-	-	-	S	S
9x9 / single / gemini-2.5-flash	-	-	-	-	-	F	F
9x9 / single / gemini-2.5-pro	-	-	-	-	-	F	F
9x9 / single / gemini-3.1-flash-lite	-	-	-	-	-	F	F
9x9 / single / gemini-3.5-flash	-	-	-	-	-	F	S



5.7 VÍ DỤ SINGLE-SHOT FAIL

```
"puzzle_id": 1,  
"difficulty": "easy",  
"model": "gemini-2.5-flash",  
"status": "Failed",  
"time_seconds": 277.5187077522278,  
"prediction": [  
  [1, 5, 3, 2, 6, 4],  
  [2, 6, 4, 5, 1, 3],  
  [5, 1, 2, 3, 4, 6],  
  [4, 3, 6, 1, 5, 2],  
  [3, 2, 5, 6, 4, 1],  
  [6, 4, 1, 5, 2, 3]]
```

- Ý nghĩa:
- Mô hình trả về một grid hoàn chỉnh.
 - Grid có vẻ hợp lệ ở một số vùng.
 - Nhưng khi so với nghiệm chuẩn, có ô sai.
 - Vì Sudoku/Killer Sudoku yêu cầu đúng toàn bộ, chỉ một ô sai cũng tính là Failed.

Model Prediction

Puzzle 01 | 6x6 | gemini-2.5-flash | Failed

3	8		17	11	
1	5	3	2	6	4
2	6	4	5	1	9
6					
5	1	2	3	4	6
13			8		
4	3	6	1	5	2
5					
3	2	5	6	4	1
9					
6	4	1	5	2	3

Ground Truth Solution

Puzzle 01 | 6x6

3	8		17	11	
1	3	5	2	6	4
2	6	4	5	1	3
6					
5	1	2	4	3	6
13			8		
6	4	3	1	5	2
5					
3	2	1	6	4	5
9					
4	5	6	3	2	1



Prediction vs Solution

Puzzle 01 | 6x6 | gemini-2.5-flash | Failed

3	8		17	11	
1	5	3	2	6	4
2	6	4	5	1	3
6					
5	1	2	3	4	6
13			8		
4	3	6	1	5	2
5					
3	2	5	6	4	1
9					
6	4	1	5	2	3

Mismatched cells: 14



5.8 VÍ DỤ MULTI-STEP THÀNH CÔNG



Reasoning: *Subgrid 3 (r3-4, c1-3) must sum to 21. The cages $r3c1+r3c2=6$ and $r4c1+r4c2+r4c3=13$ cover all cells in this subgrid except $r3c3$. Therefore, $r3c3$ must be $21 - 6 - 13 = 2$.*


Điểm đáng chú ý:

- Mô hình dùng thông tin từ cage sum.
- Mô hình kết hợp với khả năng còn lại của hàng.
- Bước đi có lý do rõ ràng.
- Validator xác nhận giá trị đúng.

Log multi-step cho phép quan sát reasoning cụ thể, không chỉ nhìn đáp án cuối.

Multi-Step Successful Placement

Puzzle 01 | 6x6 | gemini-3.5-flash | step 3: $r3c3 = 2$





5.9 PHÂN TÍCH LỖI

Trong toàn bộ kết quả hiện tại, hai nhóm lỗi chính là:

Error type	Xuất hiện ở đâu	Ý nghĩa
Incorrect Solution	Single-shot và multi-step 6x6	Model đưa ra đáp án hoặc bước đi sai
No Certain Move	Multi-step 9x9 của model yếu hơn	Model không tìm được bước chắc chắn để đi tiếp

Tức là:

- Với Incorrect Solution, model tự tin đưa ra đáp án nhưng không khớp nghiệm chuẩn.
- Với No Certain Move, model không điền sai nhưng bị kẹt vì không tìm được bước chắc chắn.
- Cả hai đều cho thấy reasoning bằng ngôn ngữ tự nhiên cần được validate bằng ground truth.




5.9 PHÂN TÍCH LỖI

Các loại lỗi theo paper:

Error Type	Mô tả
Incorrect Solution	Lời giải hoặc bước đi sai
No Certain Move	Mô hình không tìm được bước chắc chắn để đi tiếp
Surrender	Mô hình bỏ cuộc
Claimed Contradiction	Mô hình nói đề mâu thuẫn
Missing Information	Mô hình nói đề thiếu dữ kiện

Các nguyên nhân có thể:

- Bỏ sót một ràng buộc cage hoặc ràng buộc hàng/cột/khối;
- Reasoning cục bộ đúng nhưng không đúng toàn cục;
- Context quá dài làm mô hình mất thông tin.





5.10 VÌ SAO 9X9 KHÓ HƠN?




Các loại lỗi theo paper:

Tiêu chí	6x6	9x9
Số ô	36	81
Miền giá trị	1-6	1-9
Lượt gọi multi-step tối thiểu	72	162
Số tổ hợp cage	Ít hơn	Nhiều hơn
Context prompt	Ngắn hơn	Dài hơn

Vì sao 9x9 dễ fail hơn?

- Nhiều ứng viên hơn cho mỗi ô.
- Cage có nhiều tổ hợp hơn.
- Ràng buộc chồng chéo phức tạp hơn.






06

DEMO, KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Sudoku-Bench: Evaluating creative reasoning with Sudoku variants





CS106 SUDOKU-BENCH DEMO

Killer Sudoku LLM Reasoning Visualizer

6.1 DEMO

THEME



MODEL

Gemini 3.5 Flash

MAP

Puzzle 01

SPEED: 0.35

Solution Board

Puzzle 01 | 6x6 | easy

³ 1	⁸ 3	5	¹⁷ 2	¹¹ 6	4
2	6	4	5	1	⁹ 3
⁶ 5	1	⁹ 2	4	3	6
¹³ 6	4	3	⁸ 1	5	2
⁵ 3	2	¹⁰ 1	¹⁰ 6	4	⁸ 5
⁹ 4	5	6	3	2	1

Current Board

Gemini 3.5 Flash

³ 1	⁸ 3	5	¹⁷ 2	¹¹ 6	4
2	6	4	5	1	⁹ 3
⁶ 5	1	⁹ 2	4	3	6
¹³ 6	4	3	⁸ 1	5	2
⁵ 3	2	¹⁰ 1	¹⁰ 6	4	⁸ 5
⁹ 4	5	6	3	2	1

AI Reasoning Stream

Step 36/36

Success

STEP 34 r1c5 Value 6

Column 5 contains the digits 1, 2, 3, 4, and 5. The **only missing** digit in this **column** is 6, which must go into **r1c5**. This is also...

STEP 35 r1c4 Value 2

Row 1 contains the digits 1, 3, 5, 6, and 4. The **only missing** digit to complete the **row** is 2, which **forces** **r1c4** to be 2.

STEP 36 r2c4 Value 5

Row 2 is **missing only** the digit 5, which also **satisfies** the **column**, **subgrid**, and **cage** sum constraints for **r2c4**.

Previous Map

Next Map

Step

Start

Reset



6.2 HẠN CHẾ CỦA ĐỒ ÁN

1. **Dataset nhỏ hơn paper gốc:** Nhóm chỉ chạy một tập rút gọn; Chưa bao phủ toàn bộ giống như paper Sudoku-Bench.
2. **Chủ yếu tập trung Killer Sudoku:** Chưa thử nhiều variant khác như: Arrow, Thermometer, Knight...
3. **Số model còn hạn chế:** Đã mở rộng lên 4 model Gemini; Tuy nhiên vẫn nằm trong cùng hệ sinh thái Gemini, chưa so sánh với GPT/Claude/model mã nguồn mở.
4. **Chi phí multi-step cao:** 6x6 có thể cần tới 72 lượt gọi/puzzle; 9x9 cần ít nhất 162 lượt gọi/puzzle.
5. **Prompt ảnh hưởng mạnh tới kết quả:** Cùng model nhưng prompt khác thì có thể cho kết quả khác.

6.3 HƯỚNG PHÁT TRIỂN

1. **Mở rộng Dataset:** Thêm nhiều puzzle 9x9/6x6; chạy lặp nhiều lần để giảm nhiễu do sampling; phân tích thêm các lỗi No Certain Move.
2. **Thử thêm model:** Model ngoài hệ Gemini để tăng tính khách quan; model mã nguồn mở nếu có API phù hợp.
3. **Thử thêm Sudoku variants:** Arrow; Thermometer; Knight's Move; Kết hợp nhiều luật.



6.4 KẾT LUẬN




Kết luận chính

- Sudoku-Bench là một benchmark phù hợp để đánh giá suy luận ràng buộc của LLM.
- Killer Sudoku có cấu trúc ràng buộc rõ ràng và có thể validate bằng nghiệm chuẩn.
- Nhóm đã tái hiện rút gọn thực nghiệm bằng pipeline riêng.
- Trên 6x6, Gemini 2.5 Pro và Gemini 3.5 Flash nổi bật ở single-shot; Gemini 3.5 Flash nổi bật nhất ở multi-step.
- Trên 9x9, single-shot hầu hết thất bại, trong khi multi-step giúp Gemini 2.5 Pro và Gemini 3.5 Flash đạt 2/2.
- Multi-step không chỉ là cách tăng solve rate, mà còn tạo log để phân tích lỗi và correct placements.



07 THỬ NGHIỆM THÊM

*Sudoku-Bench: Evaluating creative reasoning
with Sudoku variants*






GIỚI THIỆU PHƯƠNG PHÁP

Tóm tắt:

- Phương pháp Iterative Correction Loop và Tree of Thoughts kết hợp với mô hình gemini-3.1-flash-lite để giải các câu đố Killer Sudoku.
- Mô hình *gemini-3.1-flash-lite* khi chạy ở chế độ Single-shot và Multi-step gặp nhiều khó khăn và không giải được câu nào (0/7). Việc tích hợp thêm cơ chế sửa lỗi cuốn chiếu và tìm kiếm cây đóng vai trò là một tầng tự sửa lỗi và tìm kiếm có cấu trúc, giúp cải thiện độ chính xác của mô hình.





ITERATIVE CORRECTION LOOP SINGLE-PROMPT

Ở phương pháp này, nếu bảng trả về bị lỗi:

- **Kiểm tra:** Kiểm tra từng ô so với các ràng buộc Sudoku và lồng.
- **Khóa ô đúng:** So sánh với đáp án, các ô điền đúng được giữ lại và khóa cứng, các ô sai được reset về 0.
- **Sửa lỗi đệ quy:** Bảng Sudoku chưa hoàn chỉnh được đưa ngược lại vào Prompt để yêu cầu mô hình giải tiếp các ô còn lại ở vòng sau.
- **Sampling:** Nếu giải tuần tự $temperature=0$ bị kẹt, hệ thống tự động lấy mẫu $K=3$ kết quả ở $temperature=0.7$ để chọn ra tập ô đúng lớn nhất để khóa.

→ Phương pháp này can thiệp sâu bằng code Python. Nó giúp bài toán trở nên dễ hơn sau mỗi vòng lặp vì số ô trống giảm dần. Do đó, phương pháp này có độ chính xác 100% và tốc độ nhanh.



TREE OF THOUGHTS MULTI-STEP

Tìm kiếm cây duyệt từng bước (step-by-step):


- **Đề xuất ứng viên:** Tại mỗi ô trống, gọi Prompt Điền Số $K=3$ lần ở $temperature=0.7$ để lấy các lựa chọn điền số khác nhau.
 - **Kiểm tra hợp lệ:** Xác thực nước đi dựa trên các quy tắc Sudoku và tổng lồng.
 - **Tìm kiếm DFS:** Đi thử nước đi (so với solution và constraints) và gọi đệ quy giải tiếp ô sau.
 - **Quay lui:** Nếu đi vào nhánh cụt, chương trình reset ô đó về 0 và quay lại thử nước đi ứng viên tiếp theo trong cây.
- Nếu tại một bước, cả 3 candidates của LLM đều sai, nhánh đúng bị cắt tĩa hoàn toàn, buộc DFS phải quay lui và cuối cùng thất bại. Tuy nhiên, nó giúp mô hình cải thiện tỉ lệ giải từ 0% lên 28.6% mà không cần can thiệp Heuristic.





KẾT QUẢ THỰC NGHIỆM


Sudoku Solve Rate (%) by Evaluation Method





KẾT QUẢ THỰC NGHIỆM

Average Solve Time (seconds) by Evaluation Method





CHI TIẾT ITERATIVE CORRECTION LOOP



Mã câu đố	Kích thước	Độ khó	Gốc	Thêm Heuristic	Max Depth	Thời gian chạy (s)
01	6x6	Dễ	Thất bại	Thành công	3	248.88s
02	6x6	Dễ	Thất bại	Thành công	4	57.58s
03	6x6	Dễ	Thất bại	Thành công	2	62.93s
04	6x6	Dễ	Thất bại	Thành công	3	65.21s
05	6x6	Dễ	Thất bại	Thành công	1	45.76s
06	9x9	Khó	Thất bại	Thành công	5	162.86s
07	9x9	Khó	Thất bại	Thành công	5	214.07s
Tổng	-	-	Đúng 0 / 7 câu	Đúng 7 / 7 câu	-	TB: 122.47s



CHI TIẾT TREE OF THOUGHTS



Mã câu đố	Kích thước	Độ khó	Gốc	Thêm Heuristic	Max Depth	Thời gian chạy (s)
01	6x6	Dễ	Thất bại	Thất bại	4 bước / 2 quay lui	97.82s
02	6x6	Dễ	Thất bại	Thành công	50 bước / 7 quay lui	1,064.10s
03	6x6	Dễ	Thất bại	Thất bại	0 bước	21.71s
04	6x6	Dễ	Thất bại	Thành công	36 bước / 0 quay lui	1,614.09s
05	6x6	Dễ	Thất bại	Thất bại	8 bước / 4 quay lui	1,065.75s
06	9x9	Khó	Thất bại	Thất bại	4 bước / 2 quay lui	85.02s
07	9x9	Khó	Thất bại	Thất bại	0 bước	39.79s
Tổng	-	-	Đúng 0 / 7 câu (0%)	Đúng 2 / 7 câu (28.6%)	-	TB: 574.04s



KẾT LUẬN

- **Hạn chế của mô hình:** Mô hình giá rẻ *gemini-3.1-flash-lite* bị ảo giác về tính toán số học và tổng của các lồng khi (0/7 câu đúng).
- **Phân tích so sánh hai phương pháp:**
 - Iterative Correction Loop đạt tỉ lệ đúng 100% và thời gian chạy nhanh do cơ chế khóa ô đúng giúp giảm kích thước bài toán một cách tuyến tính sau mỗi vòng lặp. Mô hình chỉ cần giải đúng một phần bảng ở mỗi bước.
 - Tree of Thoughts: Giữ đúng tinh thần của bài báo khi cố gắng hỗ trợ mô hình chứ không can thiệp quá sâu như heuristic. Dù tỉ lệ thành công thấp hơn 28.6% do tính mong manh của thuật toán khi LLM đề xuất thiếu ứng viên đúng, đây vẫn là một bước tiến lớn giúp cải thiện khả năng của mô hình giá rẻ từ 0% lên gần 30%.
 - Vấn đề nghẽn tần suất API: Thuật toán duyệt cây tạo ra số lượng API calls cực kỳ lớn trong thời gian ngắn (1 lần phân tích + 3 lần lấy mẫu cho mỗi ô), Rate Limit liên tục và làm kéo dài thời gian chạy. Trong khi đó, phương pháp sửa lỗi cuốn chiếu gọi API rất thưa thớt và ổn định hơn.

**THANK
YOU**

